Journal of Computer Applications
计算机应用, 2024, 44(9): 2683 - 2688
ISSN 1001-9081
CODEN JYIIDU
2024-09-10
http://www.joca.cn

文章编号:1001-9081(2024)09-2683-06
DOI:10.11772/j.issn.1001-9081.2023091244

基于双向对比训练的中文故事结尾生成模型

帅　奇[1],王海瑞[1],朱贵富[2*]
(1. 昆明理工大学 信息工程与自动化学院,昆明 650504; 2. 昆明理工大学 信息化建设管理中心,昆明 650504)
(*通信作者电子邮箱 yangzhubing_ye@kust.edu.cn)

摘　要: 中文故事结尾生成(SEG)是自然语言处理中的下游任务之一。基于全错误结尾的CLSEG(Contrastive Learning of Story Ending Generation)在故事的一致性方面表现较好。然而,由于错误结尾中也包含与原结尾文本相同的内容,仅使用错误结尾的对比训练会导致生成文本中原结尾正确的主要部分被剥离。因此,在CLSEG基础上增加正向结尾增强训练,以保留对比训练中损失的正确部分;同时,通过正向结尾的引入,使生成的结尾具有更强的多样性和关联性。基于双向对比训练的中文故事结尾生成模型包含两个主要部分:1)多结尾采样,通过不同的模型方法获取正向增强的结尾和反向对比的错误结尾;2)对比训练,在训练过程中修改损失函数,使生成的结尾接近正向结尾,远离错误结尾。在公开的故事数据集OutGen上的实验结果表明,相较于GPT2.ft和深层逐层隐变量融合(Della)等模型,所提模型的BERTScore、METEOR等指标均取得了较优的结果,生成的结尾具有更强的多样性和关联性。

关键词: 中文故事结尾生成;对比训练;文本采样;文本生成;自然语言处理
中图分类号: TP183　　**文献标志码:** A

Chinese story ending generation model based on bidirectional contrastive training

SHUAI Qi[1], WANG Hairui[1], ZHU Guifu[2*]
(1. *Faculty of Information Engineering and Automation, Kunming University of Science and Technology, Kunming Yunnan* 650504, *China*;
2. *Information Technology Construction Management Center, Kunming University of Science and Technology, Kunming Yunnan* 650504, *China*)

Abstract: Chinese Story Ending Generation (SEG) is one of the downstream tasks in Natural Language Processing (NLP). CLSEG (Contrastive Learning of Story Ending Generation) based on completely wrong endings performs well in terms of story consistency. However, due to the fact that the wrong ending also contains the same content as the original ending text, using only the wrong ending for contrastive training may results in the main part of the generated text with the correct ending being stripped off. Therefore, forward ending enhancement training was added on the basis of CLSEG to preserve the correct parts lost in contrastive training. At the same time, by introducing forward endings, the generated endings have stronger diversity and relevance. The proposed Chinese story ending generation model based on bidirectional contrastive training consisted of two main parts: 1) multi-ending sampling, by which positively enhanced endings and reverse contrasted erroneous endings were obtained by different model methods; 2) contrastive training, by which the loss function was modified during the training process to make the generated ending close to the positive ending and away from the wrong ending. Experimental results on the publicly available story dataset OutGen show that compared to models such as GPT2. ft and Della (Deeply fused layer-wise latent variable), the proposed model achieves better results in BERTScore, METEOR, and other indicators, generating more diverse and relevant endings.

Key words: Chinese Story Ending Generation (SEG); contrastive training; text sampling; text generation; Natural Language Processing (NLP)

0　引言

中文故事结尾生成(Story Ending Generation,SEG)是自然语言处理任务中文本生成的一个分支,旨在根据一系列故事前文生成连贯的故事结尾[1]。该任务的主要挑战在于模型需要对前文中的背景和任务等进行一定程度的建模,以生成更具关联性的结尾。这些结尾需要符合上下文的语义相关性和可读性。以往的语言模型(Language Modeling,LM)由于从左到右(left to right)生成的特点以及解码器的强大,导致生成的文本退化并出现重复问题,因此,生成的结尾在关联性和可读性方面都非常差。

在故事结尾生成任务中,Li等[2]首先采用了融入对抗训练的序列到序列模型。随后,由于注意力机制的提出,Zhao等[3]使用了基于注意力机制的Transformer模型,并引入了解决词汇表外词的前位复制机制以及梯度原则强化学习。Gupta等[4]也应用了注意力机制,不同的是,他们提出了关键词调节的方法,通过获取额外的文本词向量并在生成时进行连接,使生成的句子带有一定的关键词。然而,这些方法并没有使生成的结尾与前文更加关联,并且许多结尾甚至与前

收稿日期:2023-09-12;**修回日期:**2023-11-25;**录用日期:**2023-12-01。　**基金项目:**国家自然科学基金资助项目(61863016)。
作者简介:帅奇(1999—),男,四川眉山人,硕士研究生,主要研究方向:自然语言处理; 王海瑞(1969—),男,云南昆明人,教授,博士,主要研究方向:大数据、边缘计算; 朱贵富(1984—),男,江西赣州人,高级工程师,硕士,主要研究方向:图像处理。

文的情感相悖。而后，Mori 等[5]提出人类在理性评估结尾时应考虑情感和道德等因素。

为了解决缺乏情感等因素以及生成文本逻辑混乱、单调的问题，之前的研究者们在故事训练中引入了不同的外部因素，比如语义学[6]、常识性知识[7-9]和情感[10-11]。还有一些研究，比如 Huang 等[12]采用基于多模态的图像引导故事结尾生成（Image-Guided Story Ending Generation，IGSEG）；然而，生成的结尾与人为设定的结尾之间仍存在较大差距。主要是训练时模型学习正向结尾的选择太少，反复学习相同的正向结尾导致一定程度的过拟合，从而使生成的结尾缺乏多样性。尤其是在原结尾过于简短的情况下，生成的结尾变得乏味。

基于此，Xie 等[13]结合了 Guan 等[14]和 Arora 等[15]的成果提出了一种基于全反向结尾对比的故事结尾生成方法 CLSEG（Contrastive Learning of Story Ending Generation），使生成结尾与前文的关联性增强，但丢失了前文中应有的正确部分。为了改进单一的假结尾，本文认为有必要在与假结尾进行对比训练时，加入辅助的正向结尾增强训练。正向结尾在某些方面具有理想的特性，例如多样性和关联性。通过这种方式，在训练过程中，可以加强模型对原结尾的理解，并将它与反向的错误结尾对比，从而更好地建模故事上下文与结尾之间的一致性和合理性。因此，本文在正向增强与反向对比两个方面进行特别处理。对于正向增强结尾，本文采用了两种不同的正向结尾：首先，在多样性和关联性方面，使用了不同的前沿语言模型进行特化学习，多样性结尾使用了对比搜索（Contrastive Search，CS）解码方法[16]，而关联性结尾使用了深度逐层隐变量融合（Deeply fused layer-wise latent variable，Della）机制[17]。其次，在反向的错误结尾对比方面，本文采用了不同于 Xie 等[13]提出的情感反转方法，此方法由于目前中文情感分词网络的局限，以及中文情感反义词词汇表的缺失，选用 ChatGPT（openai. com）直接对原结尾进行修改。而第 2 种错误结尾，本文选择一个额外且不同于主数据集的副数据集，使用副数据集训练后基于主数据集前文生成结尾。

本文的主要工作如下：

1）提出了一种基于正向增强训练与反向对比训练的模型，该模型可以使生成的结尾与前文更具关联性，且相较于原结尾更具多样性。

2）在训练过程中，本文使用了多路采样（Multi-Aspect Sampling，MAS）机制和对比训练策略，同时将 MAS 分为增强结尾采样和对比结尾采样两部分。

1 正向增强与反向对比训练模型

1.1 模型结构

本文在 Xie 等[13]的模型基础上加入了正向增强结尾，具体结果如图 1 所示，总体分为多路结尾采样和对比训练。

在多路结尾采样机制中，通过不同的方式生成多个不同的结尾，然后在对比训练中将这些结尾与原结尾一起放入模型训练。所有语言训练模型均采用基于自注意力机制的 Transformer 模型[18]，具体为 GPT2[19]模型。通过一系列堆叠层将输入序列 $x = \{x_1, x_2, \cdots, x_n\}$ 表示为连续分布的隐藏状态 $h = \{h_1, h_2, \cdots, h_n\}$，并且第 l 层的状态 h_l 是用缩放的点积注意力计算的：

$$\text{Attention}(\boldsymbol{Q}, \boldsymbol{K}, \boldsymbol{V}) = \text{softmax}\left(\boldsymbol{Q}^{\mathrm{T}}\boldsymbol{K}/\sqrt{d}\right)\boldsymbol{V}^{\mathrm{T}} \tag{1}$$

其中：$\boldsymbol{Q}$、$\boldsymbol{K}$、$\boldsymbol{V}$ 分别表示查询（Query）、键（Key）、值（Value），并由前一层投影计算，$\boldsymbol{Q} = \boldsymbol{W}^{\mathrm{q}}\boldsymbol{h}^{l-1}$，$\boldsymbol{K} = \boldsymbol{W}^{\mathrm{k}}\boldsymbol{h}^{l-1}$，$\boldsymbol{V} = \boldsymbol{W}^{\mathrm{v}}\boldsymbol{h}^{l-1}$；$d$ 是隐藏层的维度。而使用的损失函数为最大似然估计（Maximum Likelihood Estimation，MLE），公式为

$$\mathcal{L}_{\text{MLE}} = -\frac{1}{|x|}\sum_{i=1}^{|x|}\log p_\theta\left(x_i | x_{<i}\right) \tag{2}$$

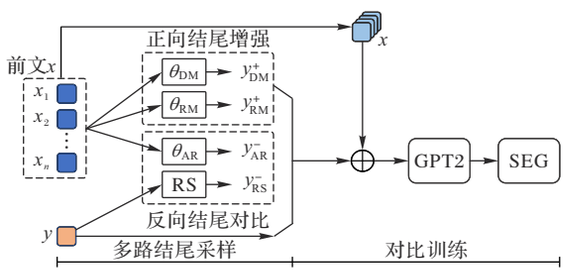


图 1 正向增强与反向对比训练模型的结构

Fig. 1 Structure of forward enhancement and reverse contrast training model

1.2 正向增强结尾采样

此机制的主要目的是获取用于增强结尾表达的文本，在训练过程中希望生成的结尾与这些文本更接近。表 1 为不同方法示例得到的结尾样本。本文的正向增强主要得益于前沿方法的研究，以模型和方法的理解带来新的样本。

表 1 不同方法生成的结尾示例

Tab. 1 Ending examples of different sampling methods

方法	示例
原结尾	马得到了好处，不再贫困，却也失去了自由。
DM	这个国家的未来到底在哪里呢？于是，他决定去寻找答案。
RM	其他三位便把他们卖去了马，救下了背上的陷阱。
RS	失去了好处，继续贫困，却重获自由
AR	马赢了，结束了这场争吵，又恢复了往日的风貌，一家欢喜几家愁。

1.2.1 多样性方法

多样性方法（Diversity Method，DM）：本文使用对比搜索方法[16]增强生成结尾的多样性。这种多样性并非简单地与前文无关，而是基于对前文的理解，使得结尾能够产生不同的表达。对比搜索能够增强模型在解码端进行文本生成时的多样性。此外，对比搜索方法也应用于其他模型的生成端。DM 可表述如下：

$$\theta_{\text{DM}} = \text{GPT2}(D_{\text{main}})$$
$$y^+_{\text{DM}} = \text{cs}(\theta_{\text{DM}}: x_{\text{main}}) \tag{3}$$

其中：D_{main} 为使用的主数据集；θ_{DM} 为训练后得到的模型参数；x_{main} 为输入的前文集合；y^+_{DM} 为生成的增强结尾集合；cs() 为对比搜索。在解码时，模型会学习拉开不同词表征之间的距离，进而提升句子内词的各向同性。根据对比搜索公式，t 时刻的词会基于 $t-1$ 时刻之前的词的概率，减去各个词与词之间的余弦相似度，进而达到生成相似而不相同的文本的效果，即为文本增加多样性。

1.2.2 关联性方法

关联性方法（Relevance Method，RM），是通过融入 Della 机制[17]，增强结尾与前文的关联性。RM 的公式如下：

$$\theta_{\text{RM}} = \text{Della}(D_{\text{main}})$$
$$y^+_{\text{RM}} = \text{RM}(\theta_{\text{RM}}: x_{\text{main}}) \tag{4}$$

其中，Della 的关键机制是基于编码器的隐变量逐层融入解码器，而隐变量之间又互相影响。Della 的结构如图 2 所示。

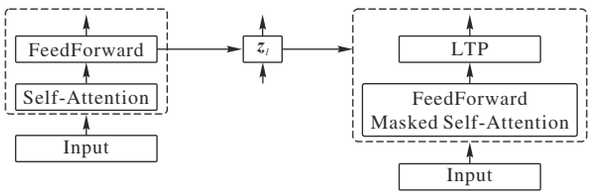


图2　Della模型结构

Fig. 2　Structure of Della model

Della会在编码器的每一层计算平均自注意力得到隐变量z_l，再通过LTP（Low-rank Tensor Product）嵌入解码器的前馈层之后，从而使解码层传入下一层时，会受到编码器传入的隐变量的影响，使前文对结尾产生更深的干预。

1.3　反向对比结尾采样

1.3.1　情感反转

情感反转（Reverse Sentiment，RS）是一种通过词替换等方式实现的方法，旨在使生成的句子情感与原始数据集的故事情感相反。通过对比具有不同情感的句子，使模型能够更加敏感地捕捉语义变化。公式可简述如下：

$$y^-_{\mathrm{RS}} = \mathrm{ChatGPT}(y) \tag{5}$$

其中，y^-_{RS}为得到的情感反转结尾，y为原故事的结尾，此部分使用的是ChatGPT3.5，prompt为“下面我会给你一个故事和对应的结尾，联系故事和结尾写一个意思相反的结尾，格式为\"意思相反结尾：\"，新结尾字数+原结尾字数+字左右。”

1.3.2　结局覆写

结局覆写（Another Rewrite，AR），是通过将GPT2在另一个数据集D_{sub}上训练生成的结尾，生成时使用D_{main}的前文，可表示为：

$$\theta_{\mathrm{AR}} = \mathrm{GPT2}(D_{\mathrm{sub}})$$
$$y^-_{\mathrm{AR}} = \mathrm{AR}(\theta_{\mathrm{AR}}: x_{\mathrm{main}}) \tag{6}$$

1.4　结尾采样示例

表1给出不同方法生成的结尾的一个示例。本文的结尾裁剪方式为：在生成足够字数的情况下，控制结尾的字数在30以内，且最好以一句为结尾。

前文：有一回，鹿和马为了一块草地争吵得不可开交，各人都想将这块草地占为己有最后鹿仗着自己那对厉害的角，终于战胜了马。这对马来说，简直是无法容忍的。怎样才能重新把鹿赶走呢？马考虑来考虑去，终于想到去求助于人。它找到了一个很强壮的男人这个人来到草地，同鹿干了一仗，将鹿杀死了。从此，这块引起纠纷的草地，完全归马独自占有了不过，那位帮助马取得胜利的男人，也已将马占为己有了。

1.5　对比训练

如图1所示，对比训练主要是在训练时将原结尾与上述的结尾共同放入GPT2模型中训练，训练的损失函数为MLE的变体，t时刻的损失函数如下：

$$\mathcal{L}^t_{\mathrm{CL}} = \left(p_\theta\left(y \mid x_{\mathrm{main}}\right), \left\{y^+_i\right\}^2_{i=1}, \left\{y^-_j\right\}^2_{j=1}\right) = -\log p_\theta\left(s^+_t \mid s^+_{<t}, c\right) - \frac{1}{|N|}\sum_{i=1}^{|N|}\log p_\theta\left(s^+_{i,t} \mid s^+_{i,<t}, c\right) - \frac{1}{|N|}\sum_{j=1}^{|N|}\log p_\theta\left(s^-_{j,t} \mid s^-_{j,<t}, c\right) \tag{7}$$

其中：c为t时刻输入的前文，s^+_t为原数据集结尾，$s^+_{i,t}$为正向增强的结尾，$s^+_{i,t} \in y^+_i$，$y^+_i \in \left\{y^+_{\mathrm{DM}}, y^+_{\mathrm{RM}}\right\}$，$s^-_{j,t}$反向对比的结尾$s^-_{j,t} \in y^-_j$，$y^-_j \in \left\{y^-_{\mathrm{RS}}, y^-_{\mathrm{AR}}\right\}$，$N$为2，目的是保持原结尾，增强结尾，对比结尾的权重为1∶1∶1。

本文将前文和所有的故事传入模型后，使模型分别计算，$\mathcal{L}$、$\mathcal{L}_{\mathrm{DM}}$、$\mathcal{L}_{\mathrm{RM}}$、$\mathcal{L}_{\mathrm{RS}}$、$\mathcal{L}_{\mathrm{AR}}$，最后通过式（7）计算$\mathcal{L}_{\mathrm{CL}}$。

2　实验与结果分析

2.1　超参数设置

模型的训练超参数值如表2所示。设备软件环境为：Unbuntu 20.04.2 LTS。硬件环境为：GPU NVIDIA GeForce RTX 4090上运行，显存24 GB；CPU Xeon Platinum 8352V。框架Transformer版本为4.26.0，PyTorch版本为2.0.0，CUDA版本为11.8。

表2　超参数设置

Tab. 2　Hyperparameter setting

超参数	值	超参数	值
总轮次	100	最大截断长度	256
批次量	8	预热步比例	10%
学习率	2×10^{-5}	生成文本长度	64
累积步率	8		

2.2　数据处理

本文使用了两个数据集，主要数据集是LOT[20]公开的OutGen故事数据集。本文对数据集的格式进行修改，删除outline和title两个分栏，并将story中的主体部分提取出来。将最后一句作为target，即结尾预期任务的结尾，而之前的句子则作为source，即结尾预期任务的前文。修改后的数据集格式为“前文+\t+结尾”。更改后的数据集参数如表3所示。

同时，基于模型方法设计的需要，本文引入了另一个副数据集，名为CFT（Children Fairy Tale）[21]。该数据集与OutGen数据集无关，更偏向小学生作文。它仅在AR的流程中使用。本文对它进行了整合和去重，使它的格式与修改后的OutGen版本相同。相关参数如表3所示。

需要注意的是，CFT数据集没有测试集部分。这是因为本文只需要用它训练模型以获取参数，并且生成的结尾是基于OutGen的前文生成的。

表3　更改后的OutGen与CFT数据集信息

Tab. 3　Information of changed OutGen and CFT datasets

数据集	类型	训练集	验证集	测试集
OutGen	样本数	1 456	729	242
	字符数	274 654	138 311	45 662
	中文字数	231 733	116 799	38 567
CFT	样本数	739	362	—
	字符数	128 579	48 389	—
	中文字数	127 631	47 994	—

2.3　评估指标

本文的评价指标主要针对生成文本进行自动评估（Automatic Evaluation，AE）。指标的值越高表示生成效果越好。以下是各个指标的详细描述：

B-n（BLEU-n）：BLEU[22]评估生成序列和参考序列的n-gram重合程度。表4~5中为B-n（n=1，2，…，4）的平均值。

D-n（Distinct-n）：Distinct[23]是评估生成结果多样性的常用指标，评估输出中不同的unigram（一元分词）和bigram（二元分词）的比例。

Cover（Coverage）：Coverage[20]评估生成的可控性，通过计算生成文本与每个输入短语之间的平均Rouge-L分数衡量。Rouge分数用于衡量自动生成结果与参考结果之间的召回相似性。

METEOR[24]：是基于单精度的加权调和平均数和单字召回率的方法，综合考虑了准确率和召回率，并给出评分。

BERTScore[25]：使用预训练的BERT获取生成文本和参考文本的向量表示，并计算它们的余弦相似度，再基于余弦相似度计算精确率（Precision）、召回率（Recall）和F1分数（F1 score）。本文的前文为cands，结尾为refs，使用的版本为v0.3.12，表4~6和表9中的分数为F1分数。

表中，最优的指标加粗表示，次优指标用下划线表示。

2.4 实验结果

AE评估的实验结果如表4所示。本文的实验结果完全基于生成文本的表现进行评估。所有模型的解码方法都使用对比搜索。基线模型是预训练的GPT2模型，而GPT2.ft是在OutGen数据集上微调后的模型。Truth表示测试数据集自身与自身的对比值。数值为0.01的值表示小数点后超过3位的情况。所有对比实验都在主数据集OutGen上进行微调。对比实验中，Della[17]、Embedding[26]、Memory[27]、Softmax[28]的设置都参考了文献[17]模型，其中Della是本文提出的RM的架构，其余3种方法都是隐变量的嵌入模型。而Simctg则是本文提出的DM方法的原架构。LOT[20]和文献[29]模型为使用OutGen数据集的模型。

从表4可以看出，本文模型在大多数质量指标上表现更好，但在多样性指标D-*n*上表现较差。这是因为D-*n*评估的是结尾与前文不同的程度，因此一些不相关甚至完全无关的内容可能会获得更高的多样性评分，尽管它们在其他指标上的得分较低。这也解释了为什么Embedding的D-*n*最高，但其余指标较低。本文参考了文献[17]中的一些观点，该论文的第5.5.2节指出，GPT2可能会产生一些格式错误的内容，通过误导指标来“提高”多样性，但这也会导致质量下降。

2.5 消融实验

本文针对不同的结尾方法进行了消融实验，结果如表5所示。“GPT2.ft+DM”表示在训练时同时使用GPT2.ft和DM两种结尾方法，其他列则表示只更换了特定的方法。损失函数的计算保持式(7)的方式，将其他值固定为0，训练比例保持1∶1。从表5可以看出，本文模型在一半的指标上占优势。在3种模型中，对于B-*n*分数，RM方法对模型的贡献最大。对于Coverage、BERTScore、METEOR分数，DM对本文模型的结果贡献最大。而对于D-*n*分数，只使用GPT2.ft的模型贡献较小，原因是相比其他模型，本文模型的D-*n*分数都有所减小。这一点与对比实验的结果一致，本文对此保持与对比实验相同的观点。

表4 不同模型的自动评估结果

Tab. 4 Automatic evaluation results for comparative experiments

模型	B-1	B-2	B-3	B-4	D-1	D-2	Cover	BERTScore/%	METEOR
Truth	100.00	100.00	100.00	100.00	36.52	84.83	100.00	60.58	9.01
GPT2	21.08	2.22	0.42	0.01	29.86	71.11	25.39	55.17	4.97
GPT2.ft[19]	24.20	3.47	0.47	0.12	31.29	73.46	28.51	56.65	5.61
Embedding[26]	16.61	0.60	0.01	0.01	**34.66**	**83.32**	23.77	51.20	4.32
Memory[27]	17.90	0.77	0.01	0.01	29.89	78.80	22.05	53.16	3.55
Softmax[28]	20.45	1.04	0.01	0.01	25.70	71.87	25.20	55.05	4.62
LOT[21]	23.15	3.60	0.45	0.15	25.32	65.01	27.32	56.12	6.70
文献[29]模型	24.58	3.92	0.67	0.27	26.01	66.61	30.49	58.75	7.72
Della[17]	21.79	3.21	0.77	0.22	30.61	75.26	22.96	55.82	4.00
Simctg[16]	26.41	5.06	0.76	0.22	29.88	72.99	31.74	59.34	7.51
本文模型	**26.48**	**6.43**	**1.40**	**0.45**	20.83	54.86	**32.35**	**60.27**	**8.38**

表5 消融实验中的自动评估结果

Tab. 5 Automatic evaluation results for ablation experiments

模型	B-1	B-2	B-3	B-4	D-1	D-2	Cover	BERTScore/%	METEOR
GPT2.ft	24.20	3.47	0.47	0.12	**31.29**	**73.46**	28.51	56.65	5.61
GPT2.ft+DM	27.12	6.18	1.22	0.43	25.98	64.50	**32.85**	60.29	8.17
GPT2.ft+RM	**27.30**	6.24	1.39	0.44	25.95	64.73	32.07	60.17	8.12
GPT2.ft+AR	25.21	4.49	0.85	0.19	22.29	58.52	30.56	59.84	7.93
GPT2.ft+RS	26.14	4.25	0.95	0.24	22.03	56.83	31.66	59.17	7.69
本文模型	26.48	**6.43**	**1.40**	**0.45**	20.83	54.86	32.35	**60.62**	**8.38**

2.6 案例研究

本文在表6中展示了对比实验的示例。示例的前文为：赵奢是赵国名将，为赵国屡建战功。而赵奢的儿子赵括从小就读了不少兵书，谈起用兵之道那是滔滔不绝，连他父亲都不如他，所以，赵括很自以为是，觉得自己是了不起的军事家。在他父亲去世后，赵括受命带兵打仗，却一再败退。原来赵括只会根据兵书来排兵布阵，不懂得随机应变。这一次败仗，彻底挫败了赵括的自信与自傲。

首先，观察生成的结尾文本，可以发现本文方法生成的结尾相比其他结尾甚至原始结尾，与前文的关联性最强。这是因为原始结尾是一种转折型结尾，其情感关系符合人类的思维逻辑，但略微偏离了纯文字的逻辑。根据表6中的评分和示例，可以得出以下结论：

1）对于在对比实验中D-*n*分数较高的Embedding和Memory方法，在实际生成的文本中与前文几乎没有关联。这说明D-*n*分数更高的倾向是生成文本越杂乱，而不一定表示生成质量更好。

2）本文方法生成的结尾在去除Embedding和Memory方法后，在所有结尾中大多数获得最优评分。这表明本文方法能够增强模型对生成结尾的多样性和关联性。

在表7中，本文总结了本文模型对不同指标的提升情况。提升比计算方式为：

$$Rate = our \Big/ \sum_{i=1}^{n} other_i \tag{8}$$

其中:*our* 为本文模型的分数;$other_i$ 为对比模型分数;n 的值为对比实验模型的模型数量。

表6　不同模型生成的结尾对比结果

Tab. 6　Comparison results of endings generated by different models

模型	生成结尾	BERTScore	METEOR
原文	他回国后开始虚心学习,争取早日成为可以抵挡一面的将军。	56.32	5.95
本文模型	从此,赵括再也不敢随便出兵了,他认为自己的兵力不如别人。	**64.67**	**9.97**
GPT2.ft	从此,赵国便一直领先着赵国一大截,赵国再也没有丢失过兵书了。	61.53	7.46
Embedding	但其后来胡杨而此事被罢而得到了赵弘为人谦明白了什么也没识到就。	54.84	5.93
Memory	就这样还总几个学识渊博的深深敬佩地称赞赏下其鬼魂和楚明感谢礼。	51.02	3.21
Softmax	最终下令释放了那些能够救活着比赛的人前来救他的人。	53.31	4.41
LOT	赵奢死后,没有儿子,就让位于颍川郡的姑臧君主被封为驱车千户。	59.73	6.82
文献[29]模型	赵奢平时最爱读书,赵奢常到赵国拜著名诗人孟浩然为师	61.98	4.91
Della	从此,赵国便十分羡慕赵国的爱戴和对自己的精神激励。	60.60	5.96
Simctg	从此,赵国便一直领先着赵国近一步,赵国也越发强大了起来。	59.66	7.09
GPT2	十年后,赵括再次登上王位,成为一个统一天下的君主。	58.28	7.25
ChatGPT3.5	自负之心使赵括功败垂成,智者须懂变通。	59.26	6.47

表7　本文模型对不同指标的提升结果

Tab. 7　Enhancements of different indicators by proposed model

指标	*Rate*/%	指标	*Rate*/%
BLEU	+39.37	BERTScore	+8.21
Distinct	−26.08	METEOR	+53.93
Coverage	+22.62		

2.7　人工评分

为了对本文方法生成的结尾质量进行更全面的评估,聘请了3名评分员,让他们从内容质量(流畅性、连贯性)和内容合理性(顺序、因果关系、情感)方面对生成的结尾进行评分;同时,要求评分员尽量不受先入为主的观念影响,特别是在涉及历史人物的故事中。具体而言,内容质量评分针对生成的结尾本身,包括文字的流畅度和内部逻辑的连贯性,其中连贯性还包括转折等要素。内容合理性评分主要考虑前文与生成结尾之间的关系,包括时间或地点的顺序关系、前因后果的因果关系、故事整体表达的情感内容是积极还是消极,以及故事中涉及的主体之间的情感趋向。评分范围为1~5,其中5为最高分,最终评分取平均值。对比实验的人工评分结果如表8所示,本文方法在大多数指标上表现为最优值。

表8　对比实验人工评估分数

Tab. 8　Manual evaluation scores of comparative experiments

模型	流畅性	连贯性	顺序	因果	情感
Embedding	2.53	2.61	2.31	1.78	1.88
Memory	2.15	2.03	2.26	1.70	2.11
Softmax	2.35	2.40	2.55	2.20	2.10
Della	3.28	3.08	2.93	2.61	2.78
Simctg	**3.60**	3.02	**3.10**	2.55	2.86
LOT	3.23	2.98	2.75	2.46	2.61
文献[29]模型	3.31	3.05	2.86	2.42	2.81
本文模型	3.52	**3.22**	2.86	**2.72**	**3.04**

2.8　与ChatGPT的对比结果

本文最后额外对比ChatGPT3.5,此时的prompt为“故事前文+请写15字结尾,不超过30字”。对比结果见表9。其中,B是B-n(n=1,2,…,4)的加和平均值,D是D-n(n=1,2)的加和平均值。

由表9可知,本文的生成方法生成的结尾,在指标上大多优于ChatGPT3.5,这是因为ChatGPT3.5倾向总结性的结尾,比如在表6中展示的结尾,而由于它强大的总结性,偶尔会导致生成的文本丢失前文的主语,比如“有时候,教训只有通过亲身经历才能真正体会”,导致它的分数会偏低,但实际是符合人的思维逻辑的。而某些故事的结尾与故事的关联性较小,会让人难以理解,比如下面这个故事:“有个聪明人给自己的两个学生出了一个难题:用一块钱买件东西并把一间黑暗的房间塞满一个学生拿这一块钱买了许多干草,摆进这个房间,房间被这许多干草塞满了另一个学生却只费了四角钱,买了一盏油灯回来他把灯点着了,房间里立刻亮了起来,灯光洒满了房间。”ChatGPT3.5的结尾为“谜底:那里本来就有窗户。”,本文的结尾为“这个学生很开心,觉得自己的生活很有意思”。总体而言,本文方法相较于ChatGPT3.5,能够生成有一定效果的开放性较强的故事结尾。

表9　本文模型与ChatGPT3.5的对比结果

Tab. 9　Comparison results between proposed model and ChatGPT3.5

模型	B	D	Cover	BERTScore/%	METEOR
ChatGPT3.5	8.03	54.64	31.21	59.26	8.54
本文模型	**8.69**	37.84	**32.35**	**60.27**	8.38

3　结语

本文针对中文故事结尾生成任务,采用了正向增强与反向对比训练的方法。考虑了不同前沿语言模型的特点,通过训练模型获取正向增强的结尾,并利用另一种方法获取反向对比的结尾。在对比训练过程中,同时使用正向增强、反向对比以及原始结尾,旨在生成更具多样性和关联性的结尾。实验结果表明,本文方法生成的结尾在关联性和多样性方面表现更好。未来的研究方向包括对结尾文本进行词性提取和标记,以使生成的结尾更符合原始结尾的语言习惯。

参考文献(References)

[1] SHARMA R, ALLEN J, BAKHSHANDEH O, et al. Tackling the story ending biases in the story cloze test [C]// Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2018:752-757.

[2] LI Z, DING X, LIU T. Generating reasonable and diversified story ending using sequence to sequence model with adversarial training [C]// Proceedings of the 27th International Conference on Computational Linguistics. Stroudsburg: ACL, 2018: 1033-1043.

[3] ZHAO Y, LIU L, LIU C, et al. From plots to endings: a reinforced pointer generator for story ending generation [EB/OL]. (2019-01-11) [2023-10-26]. https://arxiv.org/pdf/1901.03459.pdf.

[4] GUPTA P, KUMAR V B, BHUTANI M, et al. WriterForcing: generating more interesting story endings [EB/OL]. [2023-06-23]. https://arxiv.org/pdf/1907.08259.pdf.

[5] MORI Y, YAMANE H, MUKUTA Y, et al. Toward a better story end: collecting human evaluation with reasons [C]// Proceedings of the 12th International Conference on Natural Language Generation. Stroudsburg: ACL, 2019: 383-390.

[6] TU L, DING X, YU D, et al. Generating diverse story continuations with controllable semantics [C]// Proceedings of the 3rd Workshop on Neural Generation and Translation. Stroudsburg: ACL, 2019: 44-58.

[7] GUAN J, WANG Y, HUANG M. Story ending generation with incremental encoding and commonsense knowledge [J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2019, 33(1): 6473-6480.

[8] XU P, PATWARY M, SHOEYBI M, et al. MEGATRON-CNTRL: controllable story generation with external knowledge using large-scale language models [C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2020: 2831-2845.

[9] WANG J, ZOU B, LI Z, et al. Incorporating commonsense knowledge into story ending generation via heterogeneous graph networks [EB/OL]. [2023-10-26]. https://arxiv.org/pdf/2201.12538.pdf.

[10] MO L, WEI J, HUANG Q, et al. Incorporating sentimental trend into gated mechanism based transformer network for story ending generation [J]. Neurocomputing, 2021, 453: 453-464.

[11] LUO F, DAI D, YANG P, et al. Learning to control the fine-grained sentiment for story ending generation [C]// Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics. Stroudsburg: ACL, 2019: 6020-6026.

[12] HUANG Q B, HUANG C, MO L, et al. IgSEG: image-guided story ending generation [C]// Proceedings of the 2021 Findings of the Association for Computational Linguistics. Stroudsburg: ACL, 2021: 3114-3123.

[13] XIE Y, HU Y, XING L, et al. CLSEG: contrastive learning of story ending generation [EB/OL]. (2022-02-18) [2023-10-26]. https://arxiv.org/pdf/2202.09049.pdf.

[14] GUAN J, HUANG F, ZHAO Z, et al. A knowledge-enhanced pretraining model for commonsense story generation [J]. Transactions of the Association for Computational Linguistics, 2020, 8: 93-108.

[15] ARORA S, KHANDEPARKAR H, KHODAK M, et al. A theoretical analysis of contrastive unsupervised representation learning [EB/OL]. (2019-02-25) [2023-10-06]. https://arxiv.org/pdf/1902.09229.pdf.

[16] SU Y, LAN T, WANG Y, et al. A contrastive framework for neural text generation [EB/OL]. (2022-02-13) [2023-04-13]. https://arxiv.org/pdf/2202.06417.pdf.

[17] HU J, YI X, LI W, et al. Fuse it more deeply! A variational transformer with layer-wise latent variable inference for text generation [EB/OL]. [2023-01-22]. https://arxiv.org/pdf/2207.06130.pdf.

[18] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need [EB/OL]. (2017-06-12) [2023-08-11]. https://arxiv.org/pdf/1706.03762.pdf.

[19] RADFORD A, WU J, CHILD R, et al. Language models are unsupervised multitask learners [EB/OL]. [2023-05-14]. https://cdn.openai.com/better-language-models/language_models_are_unsupervised_multitask_learners.pdf.

[20] GUAN J, FENG Z, CHEN Y, et al. LOT: a story-centric benchmark for evaluating Chinese long text understanding and generation [J]. Transactions of the Association for Computational Linguistics, 2022, 10: 434-451.

[21] CUI Y, LIU T, CHEN Z, et al. Consensus attention-based neural networks for Chinese reading comprehension [EB/OL]. (2016-07-08) [2023-03-03]. https://arxiv.org/pdf/1607.02250.pdf.

[22] PAPINENI K, ROUKOS S, WARD T, et al. BLEU: a method for automatic evaluation of machine translation [C]// Proceedings of the 40th Annual Meeting on Association for Computational Linguistics. Stroudsburg: ACL, 2002: 311-318.

[23] LI J, GALLEY M, BROKETT C, et al. A diversity-promoting objective function for neural conversation models [C]// Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics. Stroudsburg: ACL, 2016: 110-119.

[24] BANERJEE S, LAVIE A. METEOR: an automatic metric for MT evaluation with improved correlation with human judgments [C]// Proceedings of the 2005 ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization. Stroudsburg: ACL, 2005: 65-72.

[25] ZHANG T, KISHORE V, WU F, et al. BERTScore: evaluating text generation with BERT [EB/OL]. (2019-04-21) [2023-02-29]. https://arxiv.org/pdf/1904.09675.pdf.

[26] LI C, GAO X, LI Y, et al. Optimus: organizing sentences via pre-trained modeling of a latent space [C]// Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2020: 4678-4699.

[27] FANG L, ZENG T, LIU C, et al. Transformer-based conditional variational autoencoder for controllable story generation [EB/OL]. [2023-09-22]. https://arxiv.org/pdf/2101.00828.pdf.

[28] WANG T, WAN X. T-CVAE: Transformer-based conditioned variational autoencoder for story completion [C]// Proceedings of the 28th International Joint Conference on Artificial Intelligence. California: IJCAI.org, 2019:5233-5239.

[29] HUANG H, TANG C, LOAKMAN T, et al. Improving Chinese story generation via awareness of syntactic dependencies and semantics [C]// Proceedings of the 2nd Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 12th International Joint Conference on Natural Language Processing (Volume 2: Short Papers). Stroudsburg: ACL, 2022: 178-185.

This work is partially supported by National Natural Science Foundation of China (61863016).

SHUAI Qi, born in 1999, M. S. candidate. His research interests include natural language processing.

WANG Hairui, born in 1969, Ph. D., professor. His research interests include big data, edge computing.

ZHU Guifu, born in 1984, M. S., senior engineer. His research interests include image processing.